



ESCUELA SUPERIOR POLITÉCNICA DEL LITORAL

FACULTAD DE INGENIERÍA EN MECÁNICA Y CIENCIAS DE LA PRODUCCIÓN (FIMCP)

Informe Técnico

Monitoreo de vehículos en regiones de interés mediante YOLO y ByteTrack

Aplicación a un estacionamiento de superficie en vista cenital

Materia: Inteligencia Artificial y Aplicaciones Mecatrónicas

Tarea: HW2 — Sistema de visión por computador con ROI

Integrantes:

- Andrea Belén Chávez Mateo
- Darwin Abelardo Jácome Cuenca
- Bryan Gabriel Zhang Plaza

Profesor: Christian Javier Tutivén Gálvez

Período: PAO 1 — 2026

Índice

1 Descripción del problema	2
2 Justificación del escenario elegido	2
2.1 Datos de entrada	3
3 Definición de la Región de Interés	3
3.1 Representación	3
3.2 Punto de referencia del objeto	3
3.3 Regiones definidas	3
3.4 Ajuste de la delimitación	4
3.5 Sobre el umbral de alerta	4
4 Estrategia utilizada para el conteo	5
4.1 Arquitectura	5
4.2 Qué significa cada cifra	5
4.3 Histéresis temporal	5
4.4 Corrección del sesgo de la histéresis	6
4.5 Alertas	6
4.6 Verificación de la lógica	6
5 Resultados obtenidos	6
5.1 Configuración reportada	6
5.2 Cómo se eligió el tamaño de inferencia	7
5.3 Rendimiento	7
5.4 Estadísticas finales	8
5.5 Resultados por región	8
5.6 Validación contra conteo manual	9
5.7 Interfaz interactiva	10
6 Limitaciones y posibles mejoras	12
6.1 Limitaciones	12
6.2 Mejoras propuestas	13
7 Conclusiones	13
8 Recomendaciones	14
Referencias	15

1 Descripción del problema

La mayoría de los estacionamientos de superficie de centros comerciales y campus universitarios funcionan sin ningún tipo de instrumentación. Quien administra el predio sabe cuántos vehículos hay dentro solo si alguien los cuenta, y sabe si un pasillo está bloqueado solo si alguien lo ve. Las alternativas instrumentadas — espiras magnéticas o sensores ultrasónicos por plaza — resuelven el problema, pero su costo crece con cada plaza que se quiera monitorear, lo que las vuelve poco atractivas para predios grandes.

Hay dos situaciones concretas que se pierden por falta de medición:

1. **No se conoce la ocupación en tiempo real.** Sin un conteo continuo por zona no hay forma de dirigir a los conductores hacia los sectores con disponibilidad. El resultado es circulación innecesaria dentro del predio, congestión interna y tiempo perdido.
2. **No se detecta la obstrucción de pasillos.** Un vehículo detenido en un pasillo — esperando una plaza, en doble fila o descargando — corta el flujo. En un pasillo de sentido único la cola se propaga hacia la entrada. Lo problemático no es que el vehículo se detenga, sino cuánto tiempo permanece detenido.

La observación de partida de este trabajo es que la cámara ya está instalada. En la mayoría de estos predios hay cámaras cenitales colocadas por seguridad, y cada una cubre decenas de plazas. El problema no es de sentido sino de procesamiento: convertir video que ya existe en cifras de ocupación y permanencia por zona.

Sobre esa base se desarrolló un sistema que detecta vehículos con un modelo YOLO preentrenado, les asigna una identidad estable en el tiempo mediante ByteTrack, y contabiliza tanto el ingreso como el tiempo de permanencia dentro de regiones de interés definidas por el usuario.

2 Justificación del escenario elegido

Entre las alternativas propuestas se eligió el escenario de estacionamientos inteligentes. Los motivos son cuatro.

El modelo preentrenado ya conoce el objeto. Los vehículos corresponden a clases del vocabulario COCO — car, motorcycle, bus, truck — con las que el modelo fue entrenado. No hace falta reentrenar ni etiquetar imágenes, y el trabajo se mantiene dentro del alcance del laboratorio de clase.

La vista cenital simplifica el criterio de pertenencia. En una vista oblicua el centro del bounding box no coincide con la posición del vehículo sobre el pavimento, y decidir si está dentro o fuera de una zona termina dependiendo de la altura del vehículo. En vista nadir el problema desaparece: el centro de la caja cae sobre el vehículo, y el vehículo está sobre el suelo. Eso permite usar un criterio geométrico simple y defenderlo sin supuestos adicionales.

El escenario obliga a medir permanencia. Es lo que separa un sistema de monitoreo de un contador de línea. En un estacionamiento no interesa cuántos vehículos pasaron, sino cuántos hay y desde cuándo.

Zonas distintas exigen reglas distintas. En las bahías permanecer es lo normal; en los pasillos permanecer es la anomalía. Esto justifica que el umbral de alerta sea un parámetro por zona y no una constante del sistema, y da sentido a definir varias regiones en lugar de una.

2.1 Datos de entrada

Propiedad	Valor
Archivo	videos/input/Track.mp4
Resolución	1920 × 1080 píxeles
Tasa de cuadros	29.97 fps
Duración	28.83 s (864 cuadros)
Punto de vista	Cenital (nadir), cámara estática
Escena	Estacionamiento de superficie con pasillos y bahías
Condiciones	Diurnas, cielo despejado

Tabla 1: Características del video utilizado.

3 Definición de la Región de Interés

3.1 Representación

Cada región de interés se define como un polígono de N vértices en coordenadas normalizadas entre 0 y 1 respecto al ancho y al alto del cuadro, y se guarda en el archivo `config/rois.json`. Trabajar en coordenadas normalizadas tiene una ventaja práctica: la configuración no depende de la resolución, de modo que las mismas regiones siguen valiendo si mañana se cambia la cámara por una de mayor resolución.

La pertenencia de un punto al polígono se evalúa con la función `cv2.pointPolygonTest` de OpenCV. Se optó por polígonos generales y no por rectángulos porque los pasillos reales no están alineados con los ejes de la imagen, y forzar un rectángulo obligaría a incluir zonas que no corresponden.

3.2 Punto de referencia del objeto

Se evalúa el centroide del bounding box contra el polígono, por lo expuesto en la sección 2. El sistema admite además el punto medio del borde inferior de la caja (opción `bottom`), que es la elección correcta en vistas oblicuas porque aproxima el punto de contacto del vehículo con el suelo. Para este video se usó el centroide.

3.3 Regiones definidas

Se definieron tres regiones, que se verificaron sobre un cuadro real del video antes de ejecutar cualquier procesamiento.

Identificador	Función	Vértices normalizados	Umbral
<code>pasillo_norte</code>	Tránsito; detectar obstrucción	(0.28, 0.235), (0.98, 0.235), (0.98, 0.35), (0.28, 0.35)	12 s
<code>bahias_centro</code>	Ocupación; permanecer es lo esperado	(0.30, 0.36), (0.74, 0.36), (0.74, 0.87), (0.30, 0.87)	—
<code>pasillo_sur</code>	Tránsito; detectar obstrucción	(0.28, 0.88), (0.78, 0.88), (0.78, 0.975), (0.28, 0.975)	12 s

Tabla 2: Regiones de interés definidas. El umbral es el tiempo de permanencia a partir del cual se emite una alerta.




Figura 1: Verificación de las tres regiones sobre el cuadro 200, con rejilla de coordenadas normalizadas. En ámbar el pasillo norte, en azul las bahías centrales y en verde el pasillo sur.

3.4 Ajuste de la delimitación

La primera versión del pasillo norte llegaba hasta $x = 0.02$ e incluía la vía de acceso curva, el cantero ajardinado y el paso peatonal. Al revisar la imagen de verificación quedó claro que esa delimitación era incorrecta: un vehículo detenido cediendo el paso en el cruce peatonal habría disparado una alerta de obstrucción, y el falso positivo no sería culpa del detector sino de haber trazado mal la zona. El límite izquierdo se movió a $x = 0.28$, donde aparecen las marcas viales NO ENTRY y EXIT ONLY que señalan el inicio del pasillo interno.

Vale la pena señalar que este ajuste se hizo antes de procesar el video, y no después de ver resultados que no gustaban.

3.5 Sobre el umbral de alerta

Los 12 s adoptados para los pasillos son un parámetro de diseño, no una medición. El criterio fue que un vehículo circulando normalmente atraviesa el pasillo en mucho menos tiempo, de modo que superar el umbral implica que se detuvo.

Los resultados permiten revisar esa elección a posteriori: la permanencia máxima registrada en el pasillo norte fue de 3.47 s, muy por debajo del umbral. El valor resulta conservador. Calibrarlo con rigor exigiría secuencias que contengan detenciones reales, y el video disponible no las tiene.

4 Estrategia utilizada para el conteo

4.1 Arquitectura




Figura 2: Flujo de procesamiento. El monitor de ROI guarda un estado por cada par (identificador de seguimiento, región) y alimenta las tres salidas.

El monitor mantiene un diccionario indexado primero por identificador de seguimiento y luego por región. En cada cuadro, para cada objeto rastreado y cada región, se evalúa la pertenencia y se actualiza la máquina de estados que le corresponde.

4.2 Qué significa cada cifra

Antes de reportar resultados conviene fijar el significado de los términos, porque varios de ellos admiten más de una lectura:

- **Objeto único:** un identificador distinto asignado por ByteTrack.
- **Visita:** cada transición confirmada de fuera a dentro de una región.
- **Tiempo de permanencia por objeto:** cuadros confirmados dentro de la región divididos por la tasa de cuadros, sumando todas sus visitas.
- **Tiempo promedio de permanencia:** media del valor anterior sobre los objetos que registraron al menos una visita. Se reporta también la media por visita, que difiere de la anterior cuando hay reingresos.
- **Ocupación máxima simultánea:** el mayor número de objetos dentro de la región en un mismo cuadro, a lo largo de todo el video.

4.3 Histéresis temporal

Aplicar la prueba de pertenencia cuadro a cuadro, sin más, no funciona. La caja de un vehículo situado justo sobre el borde del polígono oscila entre dentro y fuera, y el sistema termina registrando decenas de visitas para un único evento físico. Eso arruina tanto el conteo como el tiempo promedio.

Para evitarlo se exige persistencia: una entrada se confirma después de tres observaciones consecutivas dentro, y una salida después de cinco consecutivas fuera. La asimetría es deliberada. Salir cuesta más que entrar porque una oclusión breve — un poste, la sombra de un árbol — no debe interpretarse como que el vehículo abandonó la zona.

4.4 Corrección del sesgo de la histéresis

La histéresis tiene un efecto secundario que hay que corregir. Si la entrada se confirma dos cuadros tarde y la salida cuatro cuadros tarde, cada visita queda inflada en dos cuadros. Con los parámetros usados, un objeto que estuvo exactamente 20 cuadros dentro se reportaría como 22.

No es un error grande, pero es sistemático, y un error sistemático en la magnitud que se está midiendo no puede dejarse pasar. El sistema lo compensa de forma explícita: al confirmar la entrada acredita hacia atrás los cuadros en que el objeto ya estaba dentro, y al confirmar la salida descuenta los cuadros que contabilizó mientras el objeto ya estaba fuera. La prueba 1 de `src/test_roi_logic.py` verifica el resultado: 20 cuadros dentro se reportan como 20.

4.5 Alertas

Cuando la visita en curso de un objeto supera el umbral de su región, el sistema emite una alerta. Se emite una sola vez por visita, no una por cuadro, y el estado se reinicia cuando se confirma la salida. Las alertas aparecen como banda sobre el video, quedan registradas en `outputs/alertas.csv` y se muestran en vivo en la interfaz.

4.6 Verificación de la lógica

La lógica de permanencia se implementó desacoplada del detector. Esto no fue una decisión estética: permite someterla a prueba con detecciones sintéticas, sin modelo, sin GPU y en segundos, lo que hizo posible detectar el sesgo descrito en 4.4 antes de procesar un solo cuadro de video real.

El conjunto de pruebas `src/test_roi_logic.py` cubre ocho comportamientos: entrada y salida simple, supresión de visitas espurias por histéresis, reingreso, emisión de alertas, regiones múltiples simultáneas, cierre de visita cuando el objeto abandona el encuadre, consistencia de las tablas de estadísticas y el caso de un video sin detecciones. Las ocho se superan.

5 Resultados obtenidos

5.1 Configuración reportada

Parámetro	Valor
Modelo	yolo26l.pt (preentrenado en COCO, 80 clases)
Seguimiento	ByteTrack (bytetrack.yaml)
Clases COCO	2 car, 3 motorcycle, 5 bus, 7 truck
Umbral de confianza	0.35
Tamaño de inferencia	3200 px
Punto de referencia	Centroide del bounding box
Histéresis entrada / salida	3 / 5 cuadros
Hardware	NVIDIA GeForce RTX 4060 Laptop GPU
Entorno	PyTorch 2.10.0+cu128, CUDA habilitado

Tabla 3: Configuración con la que se obtuvieron los resultados reportados.

5.2 Cómo se eligió el tamaño de inferencia

Las primeras ejecuciones detectaban dos vehículos por cuadro en una escena con más de cien autos visibles. Bajar el umbral de confianza de 0.35 a 0.15 apenas lo movió a cinco, lo que descartaba el umbral como causa. Se hizo entonces un barrido sobre el cuadro 200, comparando dos formas de tratar objetos pequeños: reescalar el cuadro completo, o dividirlo en mosaicos solapados y detectar en cada uno a escala nativa.

Estrategia	Configuración	Detecciones	ms/cuadro
Reescalado global	1280 px	2	—
Reescalado global	1600 px	6	—
Reescalado global	1920 px	33	—
Reescalado global	2560 px	47	189
Reescalado global	3200 px	113	334
Reescalado global	4096 px	150	610
Mosaicos 2×2	1280 px por mosaico	14	180
Mosaicos 2×3	1280 px por mosaico	60	342
Mosaicos 3×4	1280 px por mosaico	92	611
Mosaicos 4×6	1280 px por mosaico	128	1389

Tabla 4: Barrido de estrategias de detección sobre el cuadro 200.

El barrido dejó dos cosas claras.

La primera es que el reescalado global le gana a los mosaicos, algo contrario a lo que suele recomendarse para objetos pequeños. A costo comparable — 334 ms contra 342 ms — el reescalado a 3200 px detecta 113 objetos y la grilla 2×3 detecta 60. En el extremo la diferencia se agranda: 150 detecciones en 610 ms contra 128 en 1389 ms. La estrategia de mosaicos se descartó por esta evidencia, no por suposición.

La segunda es que el umbral de confianza no hace nada en este modelo. Ejecuciones completas con 0.15, 0.25 y 0.35 dieron resultados idénticos hasta el tercer decimal en todas las métricas. La explicación está en la arquitectura de YOLO26, que trabaja de extremo a extremo sin supresión de no-máximos: la cabeza de asignación uno a uno emite una predicción confiada o no emite ninguna, y no genera la distribución continua de puntuaciones sobre la que un umbral podría actuar. Conviene tenerlo presente al portar configuraciones desde modelos basados en supresión de no-máximos, donde ese mismo parámetro sí es determinante.

Se adoptó 3200 px como punto de operación. Se pierden 37 detecciones respecto de 4096 px, pero el tiempo de inferencia se reduce a la mitad.

5.3 Rendimiento

Métrica	Valor
Cuadros procesados	864
Tiempo total de procesamiento	358.97 s
Tasa de procesamiento	2.41 fps
Tasa del video	29.97 fps
Razón respecto a tiempo real	0.08×

Tabla 5: Rendimiento de la configuración adoptada.

El sistema no opera en tiempo real con esta configuración. Procesar 28.83 s de video tomó 358.97 s, casi doce veces la duración del material.

La causa es la resolución de inferencia, no el hardware ni el tamaño del modelo. Con 1280 px el sistema alcanzaba unos 10 fps — que sigue siendo $0.33\times$, tampoco tiempo real — pero detectaba dos vehículos por cuadro, y con eso ninguna estadística tiene sentido. El compromiso entre exhaustividad y latencia queda cuantificado en la tabla de 5.2, y la decisión fue privilegiar la exhaustividad porque un sistema rápido que no ve nada no sirve para nada.

5.4 Estadísticas finales

Métrica	Valor
Total de objetos detectados (identificadores únicos)	283
Objetos que ingresaron a alguna región	80
Visitas totales a todas las regiones	168
Tiempo promedio de permanencia global	1.93 s
Alertas emitidas	0

Tabla 6: Estadísticas globales de la secuencia completa.

Los 203 objetos que no ingresaron a ninguna región son vehículos estacionados en las filas superiores y en el perímetro, fuera de las tres zonas definidas. Que aparezcan en el conteo global es correcto: el sistema rastrea todo el encuadre y la pertenencia a una región es un filtro posterior.

Las cero alertas merecen una aclaración, porque a primera vista podrían leerse como un fallo. No lo son: ningún vehículo permaneció más de 12 s en un pasillo durante los 28.83 s del video, y la permanencia máxima en el pasillo norte fue de 3.47 s. El material simplemente no contiene el evento que el mecanismo busca. Que el mecanismo funciona se verificó por separado, con detecciones sintéticas, en la prueba 4 del conjunto descrito en 4.6.

5.5 Resultados por región

Región	Objetos únicos	Visitas	Media/obj. (s)	Media/vis. (s)	Mediana (s)	Máximo (s)	Ocup. máx.
pasillo_norte	27	30	1.094	0.984	0.801	3.470	3
bahias_centro	60	135	2.354	1.046	0.968	25.359	8
pasillo_sur	3	3	0.979	0.979	0.400	2.202	1

Tabla 7: Resultados por región. Ninguna emitió alertas.

Al revisar estas cifras aparece una anomalía. Un vehículo que entra a una zona y se queda ahí debería registrar una visita, no más. En las bahías la razón entre visitas y objetos es 2.25, y un objeto llega a diez visitas. Como los autos estacionados no se mueven, esas visitas no corresponden a nada real.

Para localizar la causa se cruzaron tres indicadores por región:

Región	Visitas/objeto	Confianza mediana	Permanencia < 0.5 s
pasillo_norte	1.11	0.528	26 %
pasillo_sur	1.00	0.551	67 %
bahias_centro	2.25	0.395	35 %

Tabla 8: Indicadores de fiabilidad por región, calculados sobre outputs/permanencia_por_objeto.csv.

El patrón es consistente: donde la confianza de detección es alta la razón de visitas es prácticamente uno, y donde la confianza cae la razón se dispara. La cadena causal es directa. Menor confianza produce detecciones intermitentes; la intermitencia rompe la asociación de ByteTrack; cuando el vehículo reaparece recibe un identificador nuevo y el sistema lo cuenta como visita nueva. Como la escena, el modelo y los parámetros son los mismos en las tres regiones, la única variable que cambia es qué tan bien se detecta cada zona.

Por qué las bahías se detectan peor tiene una explicación geométrica. Los vehículos están estacionados en filas contiguas, casi tocándose, y en vista nadir sus siluetas se solapan. La cabeza de asignación uno a uno de YOLO26 castiga precisamente esa situación, porque debe emitir una sola predicción por objeto sin el respaldo de la supresión de no-máximos.

Esto tiene una consecuencia práctica sobre cómo leer los resultados. Las cifras de pasillo_norte y pasillo_sur son consistentes y utilizables. Las de bahias_centro sobreestiman las visitas y subestiman la permanencia, y deben tratarse como una cota inferior de la ocupación real, no como una medición. Conviene destacar que fue el propio sistema el que permitió identificar el problema: la razón de visitas por objeto señaló la zona poco fiable antes de disponer de cualquier conteo manual.

Un último dato descarta que el problema esté en la lógica de monitoreo. El objeto con identificador 8 permaneció 760 cuadros dentro de bahias_centro, es decir 25.36 s de los 28.83 s del video. Cuando la detección es estable la máquina de estados acumula permanencia correctamente durante toda la secuencia. El resto de objetos de esa zona no lo logra porque el detector se corta, no porque el monitor falle.

5.6 Validación contra conteo manual

Se hizo un conteo manual de referencia reproduciendo el video cuadro a cuadro y anotando los vehículos que ingresan a cada pasillo durante los 28.83 s. La región bahias_centro se excluyó de la validación por dos razones: con sesenta vehículos densamente estacionados el conteo manual no es practicable, y la sección 5.5 ya estableció que sus mediciones no son fiables.

Región	Conteo manual	Conteo del sistema	Error absoluto	Error relativo
pasillo_norte	24	27	+3	+12.5 %
pasillo_sur	3	3	0	0.0 %

Tabla 9: Conteo del sistema contra conteo manual de referencia.

El error en el pasillo norte es de sobreconteo, que es exactamente el sesgo que predecía el análisis de 5.5: la fragmentación de trayectorias solo puede sumar conteos, nunca restarlos. La magnitud, +12.5 %, es coherente con la razón de visitas por objeto de 1.11 medida de forma independiente para esa misma región. Dos caminos distintos apuntan al mismo número, lo que refuerza la interpretación.

La coincidencia exacta en el pasillo sur no debe leerse como exactitud perfecta. Con tres objetos, un solo error habría dado un error relativo del 33 %. El resultado es consistente con lo observado en el pasillo norte, pero por sí solo no alcanza para concluir nada.

5.7 Interfaz interactiva

La interfaz desarrollada con Streamlit organiza el trabajo en tres etapas: definir y verificar las regiones, procesar el video con visualización en vivo, y revisar estadísticas con exportación de resultados.




Figura 3: Etapa 1. Definición de regiones y verificación sobre un cuadro real, con control deslizante para elegir el cuadro de referencia.



Figura 4: Etapa 2. Procesamiento con barra de progreso y vista en vivo del cuadro anotado: bounding boxes, identificadores de seguimiento, tiempos de permanencia y regiones superpuestas, junto a la tabla de ocupación instantánea.



Figura 5: Etapa 3. Estadísticas finales y resumen por región.

Permanencia por objeto													
track_id	clase	confianza_promedio	frame_primera_deteccion	frame_ultima_deteccion	tiempo_visible_s	roi_id	roi_nombre	visitas	frames_dentro	tiempo_en_roi_s	visita_mas_larga_s	frame_primera_entrada	frame_ultima_salida
3	car	0.5802	0	186	5.939	bahias_centro	Bahías de parqueo centrales	1	73	2.436	2.436	0	186
8	car	0.4344	0	858	22.122	bahias_centro	Bahías de parqueo centrales	10	760	25.359	5.372	0	858
17	car	0.3719	0	16	0.267	bahias_centro	Bahías de parqueo centrales	1	9	0.3	0.3	8	17
47	car	0.3985	12	318	3.704	bahias_centro	Bahías de parqueo centrales	8	115	3.837	1.335	31	318
58	car	0.3777	18	514	4.805	bahias_centro	Bahías de parqueo centrales	8	149	4.972	1.468	43	495
77	car	0.4182	32	388	9.076	bahias_centro	Bahías de parqueo centrales	6	287	9.576	4.104	32	388
80	car	0.3781	33	45	0.367	bahias_centro	Bahías de parqueo centrales	1	13	0.434	0.434	33	45
87	car	0.3883	37	39	0.1	bahias_centro	Bahías de parqueo centrales	1	3	0.1	0.1	37	41
89	car	0.4031	37	112	1.001	bahias_centro	Bahías de parqueo centrales	2	29	0.968	0.567	52	107
91	car	0.3842	43	70	0.3	bahias_centro	Bahías de parqueo centrales	1	8	0.267	0.267	43	52

Alertas

Ningún objeto superó el umbral de permanencia configurado.

Exportacion

Escribir CSV y XLSX en outputs/

resumen_por_roi.csv permanencia_por_objeto.csv objetos.csv alertas.csv

Descargar video anotado

Figura 6: Etapa 3, continuación. Permanencia por objeto, registro de alertas y exportación a CSV y XLSX.

La interfaz procesó la secuencia completa y devolvió los mismos valores que la ejecución por línea de comandos: 283 objetos, 168 visitas, ninguna alerta. La coincidencia era esperable, porque ambas rutas consumen el mismo generador de procesamiento, y sirve para confirmar que la interfaz no introduce cálculos propios.

6 Limitaciones y posibles mejoras

6.1 Limitaciones

Detección de vehículos densamente estacionados. Es la limitación principal, y está cuantificada en 5.5: confianza mediana de 0.395 y 2.25 visitas por objeto en las bahías, contra 0.53 y 1.05 aproximadamente en los pasillos. El modelo preentrenado en COCO no logra detección estable de vehículos contiguos en vista nadir, y por eso las métricas de esa región no sirven como medida de ocupación.

Fragmentación de trayectorias. Un identificador de seguimiento no equivale a un vehículo físico. El conteo de objetos únicos es una cota superior del número real de vehículos, y el número de visitas una cota superior del número real de ingresos. El efecto es despreciable en los pasillos y sustancial en las bahías.

No hay operación en tiempo real. Con una razón de $0.08\times$ el sistema sirve para análisis diferido, no para monitoreo en vivo.

Semántica de la región de bahías. El polígono incluye los carriles de circulación que quedan entre las filas. Un vehículo que transita por ellos buscando plaza se cuenta como ocupación. La métrica hay que leerla como ocupación de la zona de bahías, no como plazas ocupadas.

Vehículos preexistentes. Los autos ya estacionados en el primer cuadro se cuentan como presentes sin que se haya observado un evento de entrada. En esa región se está midiendo un estado, no un flujo.

Umbral de alerta no calibrado. Los 12 s salen de un criterio de diseño. El video no contiene detenciones prolongadas, así que la permanencia máxima en tránsito (3.47 s) sugiere que el umbral es conservador, pero no permite calibrarlo.

Alcance experimental. Un solo video de 28.83 s, una cámara estática, condiciones diurnas y despejadas. No hay evidencia sobre el comportamiento bajo lluvia, de noche o con cámara en movimiento. Tampoco se dispone de precisión ni exhaustividad del detector sobre este dominio: las cifras publicadas de YOLO26 corresponden a COCO y no son transferibles a vista cenital.

Muestra insuficiente en el pasillo sur. Con tres objetos, ninguna estadística de esa región es representativa.

6.2 Mejoras propuestas

Mejora	Limitación que resuelve	Prioridad
Ajuste fino del modelo con imágenes etiquetadas de vista cenital	Detección en bahías densas; permitiría medir precisión y exhaustividad sobre el dominio real	Alta
Reidentificación por apariencia (BoT-SORT con ReID)	Fragmentación de trayectorias	Alta
Ampliar el parámetro track_buffer de ByteTrack	Fragmentación por pérdidas breves de detección	Media
Exportar a TensorRT o usar precisión reducida; variantes yolo26n o yolo26s	Razón respecto a tiempo real	Media
Redefinir las bahías como polígonos por fila, excluyendo los carriles	Ambigüedad semántica de la región	Media
Calcular la homografía al plano del suelo	Permitiría definir regiones en metros y medir velocidad real	Baja
Calibrar umbrales con la distribución empírica de permanencias, sobre secuencias con detenciones reales	Umbral no calibrado	Baja
Persistir en base de datos temporal en lugar de archivos CSV	Operación continua	Baja

Tabla 10: Mejoras propuestas, ordenadas por prioridad.

7 Conclusiones

- El sistema cumple el objetivo planteado. Detecta vehículos con YOLO, mantiene su identidad con ByteTrack y contabiliza ingreso y tiempo de permanencia en tres regiones definidas sobre un video de estacionamiento en vista cenital, generando el video anotado, las estadísticas finales y su exportación a archivos tabulares.
- El conteo en los pasillos es exacto dentro de un margen conocido. El sistema reportó 27 objetos contra 24 contados manualmente en el pasillo norte, un error de +12.5 %, y coincidió exactamente en el pasillo sur. El error es de sobreconteo, que es la dirección que predice la fragmentación de trayectorias identificada como su causa, y su magnitud coincide con la razón de visitas por objeto medida de forma independiente.

- En vista cenital el tamaño de inferencia pesa mucho más que el umbral de confianza. Pasar de 1280 a 4096 px llevó las detecciones de 2 a 150, mientras que mover el umbral entre 0.15 y 0.35 no cambió ningún resultado. Este segundo comportamiento se explica por la arquitectura sin supresión de no-máximos del modelo empleado, y no debería asumirse al trabajar con modelos de otra familia.
- La inferencia por mosaicos resultó peor que el reescalado global, en contra de lo que suele recomendarse para objetos pequeños. A costo comparable detectó la mitad de objetos, y en su mejor configuración fue más lenta y menos exhaustiva. La recomendación general no se sostuvo para este material, y solo el barrido experimental permitió verlo.
- La razón entre visitas y objetos únicos funciona como indicador de fiabilidad por zona. Su desviación respecto de uno señaló la degradación de la medición en las bahías antes de tener cualquier conteo manual, y su correlación con la confianza mediana de detección permitió atribuir la causa al detector y no a la lógica de monitoreo. Es una métrica barata que conviene incorporar a cualquier sistema de este tipo.
- La principal limitación es del detector, no del diseño. El modelo preentrenado no sostiene detección estable de vehículos densamente estacionados en vista nadir, lo que inutiliza la medición de ocupación en las bahías. El caso del objeto 8, rastreado durante 25.36 s de forma continua, muestra que la lógica de permanencia responde correctamente cuando la detección acompaña.
- Separar la lógica de permanencia del detector fue una decisión acertada. Permitted probarla con detecciones sintéticas en segundos, y así se descubrió el sesgo sistemático de la histéresis antes de procesar un solo cuadro de video real. De haberse mantenido acoplada, el error habría llegado sin ser detectado hasta los resultados finales.

8 Recomendaciones

- Antes de reportar cualquier cifra, verificar las regiones sobre un cuadro real del video. Definir polígonos estimando coordenadas en el código es una fuente de errores que no se manifiestan como fallos, sino como resultados plausibles pero equivocados. El ajuste del pasillo norte descrito en 3.4 es un ejemplo concreto.
- Cuando un detector rinde por debajo de lo esperado, medir antes de corregir. En este trabajo la hipótesis inicial apuntaba a los umbrales de ByteTrack, y una prueba que separó detecciones puras de detecciones rastreadas la descartó en pocos minutos. Ajustar parámetros a ciegas habría consumido mucho más tiempo.
- No trasladar recomendaciones generales sin verificarlas sobre el material propio. La inferencia por mosaicos es la respuesta estándar para objetos pequeños y aquí resultó inferior al reescalado global.
- Para llevar este sistema a operación real, priorizar el ajuste fino con imágenes etiquetadas de la propia cámara. Es la única de las mejoras propuestas que ataca la limitación principal; el resto mitiga sus efectos.
- Si el requisito es monitoreo en vivo, aceptar el compromiso de forma explícita. Reducir la resolución de inferencia acelera el sistema pero degrada la detección de forma severa, y conviene decidir a partir de la tabla de 5.2 en lugar de fijar un valor por defecto.
- Reportar siempre la razón de visitas por objeto junto a los conteos. Es la métrica que hizo evidente la zona no confiable, y no cuesta nada calcularla.

- Ampliar la validación a secuencias más largas y con detenciones reales. La actual sostiene conclusiones sobre el pasillo norte, pero las tres observaciones del pasillo sur no alcanzan, y sin detenciones prolongadas el umbral de alerta no puede calibrarse.

Referencias

1. Ultralytics. YOLO26 — Documentación de modelos. <https://docs.ultralytics.com/models/yolo26>
2. Ultralytics. Modo de seguimiento (Track) — Documentación. <https://docs.ultralytics.com/modes/track>
3. Zhang, Y. *et al.* ByteTrack: Multi-Object Tracking by Associating Every Detection Box. *European Conference on Computer Vision (ECCV)*, 2022.
4. Bradski, G. The OpenCV Library. *Dr. Dobb's Journal of Software Tools*, 2000.
5. Lin, T.-Y. *et al.* Microsoft COCO: Common Objects in Context. *European Conference on Computer Vision (ECCV)*, 2014.